ER Clinic e a IA na rotina da clínica: o que se usa, onde e por quê

Disciplina: Tecnologias Inteligentes Aplicadas à Saúde

Aluno: Romeo Noro Guterres

1. Contexto

A ER Clinic é uma healthtech de Santa Maria que desde 2015 vende, por assinatura mensal, um sistema web de gestão para clínicas e consultórios. Na palestra, os dois bacharéis em Sistemas de Informação que a representaram partiram de uma ideia simples: a pergunta deixou de ser se a IA vai chegar à saúde, e passou a ser o que fazer com o tempo que ela devolve aos profissionais. A empresa também aplica IA fora da saúde, no *Treino Scout*, que sugere treinos a partir do desempenho de atletas. Este relatório organiza o que foi apresentado por **família de técnica** e, em cada uma, discute se ela combina com o problema que resolve.

2. Regras do jogo: quem faz o quê e sob quais limites

- **Divisão de trabalho.** O que é repetitivo vai para a IA; o que é analítico fica com IA e profissional juntos; a relação com o paciente é só do profissional.
- **Regra de ouro.** A IA analisa, organiza, sugere e acelera. Interpretar, contextualizar, decidir e responder pelo resultado é do profissional.
- **IA não é verdade.** O modelo aprende padrões e devolve probabilidades; pode errar, reproduzir vieses e soar convincente mesmo errado. Daí as camadas de proteção (por exemplo, temperatura zero) descritas a seguir.
- **Regulação.** A Resolução CFM nº 2.454/2026 pede mais supervisão humana quanto maior o risco da decisão. Pela LGPD, dado de saúde é dado pessoal sensível. Os palestrantes lembraram que usar IA na clínica não é "abrir o ChatGPT": o uso precisa ser auditável e parametrizável.

3. Técnicas e os cenários em que aparecem

3.1 Aprendizado de máquina clássico: prever faltas

Cenário: avisar a recepção quando um agendamento tem alta chance de não comparecer. **Técnica:** aprendizado supervisionado com XGBoost (árvores de decisão combinadas por *gradient boosting*), tratando o problema como classificação binária. O modelo treina com o histórico da própria plataforma (faltas anteriores, dia e horário, convênio), em que o desfecho já é conhecido. Ao criar uma consulta, ele devolve uma probabilidade de falta, mostrada em faixas de risco. O desempenho é medido por ROC AUC, Average Precision e Brier Score (esta última avalia se as probabilidades são bem calibradas). Foi o único exemplo sem LLM, e serviu para provar que "a IA vai muito além das LLMs". O alerta sobre as *features* (a venda de sorvete "prevê" afogamentos, mas não os causa) lembra que o modelo só vê correlação.

3.2 LLM com *Prompt Engineering*: conversar, transcrever e resumir

É a família mais frequente, em três cenários. **(a) Chatbot de WhatsApp:** atende 24 horas e agenda sozinho, com LLM, fluxo de agentes, RAG sobre a API da própria ER Clinic e orquestração no N8N. **(b) Transcrição da consulta:** o áudio vai para um reconhecimento de fala (ASR/STT), e a LLM transforma o texto em evolução, história da doença atual, hipótese diagnóstica, medicações e plano, sempre com revisão do profissional. **(c) Resumo do prontuário:** um algoritmo próprio varre as estruturas do prontuário e monta um histórico coerente, que só então vai à LLM (via OpenRouter, depois de testes com modelos de sumarização do Hugging Face). O resultado traz referências navegáveis e se atualiza de forma incremental. Os recursos (a) e (b) hoje usam um parceiro, e a empresa quer construir os seus.

Sobre onde transcrever, vi duas saídas: mandar o áudio em pedaços ao servidor ou transcrever no frontend e enviar só o texto. Minha sugestão é transcrever de forma nativa, como fazem os áudios do

WhatsApp e as gravações do Android, com o servidor guardando áudio e texto e devolvendo apenas o texto ao cliente.

3.3 Modelo multimodal: ler exames

Cenário: o paciente envia foto ou PDF de um exame. **Técnica:** uma LLM multimodal recebe o arquivo (em Base64), compara cada resultado com a referência da clínica e devolve um JSON estruturado, que vira registros no histórico e alimenta os gráficos de evolução; ao final, gera um parecer de apoio. Antes, o fluxo usava OCR (PyMuPDF e Tesseract). Django e Celery cuidam do processamento assíncrono. Como o resultado é só apoio à análise, a decisão segue com o profissional.

3.4 RAG: o copiloto Córtex

Cenário: o profissional quer condutas, exames e tratamentos fundamentados nos protocolos da própria clínica. **Técnica:** RAG (*Retrieval-Augmented Generation*): os documentos são extraídos e divididos em trechos (*chunking*), convertidos em vetores (OpenAI text-embedding-3-small) e guardados em uma base vetorial (Pinecone). Na consulta, a busca semântica recupera trechos, o Cohere Rerank reordena os mais pertinentes e a LLM (GPT-5 ou Gemini Flash, configurável por copiloto) redige a resposta com referências. O backend é uma API Django com Celery e Redis. O desafio declarado é recuperar os trechos certos e checar se a resposta bate com as fontes.

4. A técnica combina com o problema?

Pergunta que o cenário faz	Técnica usada	Avaliação
Quem provavelmente vai faltar? (dados em tabela, resultado sim/não)	XGBoost supervisionado	Adequada. Padrão estatístico em dados estruturados; LLM seria cara e menos precisa.
Como conversar e agendar a qualquer hora? (linguagem livre)	LLM + agentes + RAG na API	Adequada. Precisa entender texto e consultar a agenda real; falha se alucinar horários.
O que foi dito na consulta? (áudio)	ASR/STT + LLM	Adequada. Duas etapas distintas, com revisão humana no fim.
O que importa neste prontuário extenso? (texto longo)	Pré-processamento próprio + LLM	Adequada, mas só funcionou com a etapa de preparação; a LLM sozinha não bastava.
O que este exame mostra? (foto ou PDF)	LLM multimodal (antes, OCR)	Adequada. Um modelo só lê e interpreta, mas exige conferência.
O que dizem os nossos protocolos? (base privada)	RAG com reranking	Muito adequada. Mantém a resposta presa à fonte da clínica.

A regra que se repete é escolher a técnica pelo **formato do dado**: tabela pede aprendizado supervisionado; áudio pede reconhecimento de fala; documento e imagem pedem modelo multimodal; conhecimento próprio pede RAG. Quando o texto é longo e confuso, preparar os dados antes da LLM importa tanto quanto o modelo.

Pontos de atenção que eu levantaria: (1) a temperatura zero reduz a variação, mas não elimina erros, então a revisão humana e a rastreabilidade continuam indispensáveis; (2) o modelo de faltas usa variáveis como o convênio, e convém verificar se ele não passa a tratar mal grupos específicos de pacientes; (3) vários recursos dependem de parceiros e de serviços externos (OpenRouter, OpenAI, Pinecone, Cohere), o que pesa por se tratar de dado sensível na LGPD e explica o desejo de desenvolver soluções próprias.

5. Relação com o conteúdo das aulas

5.1 Técnicas de IA utilizadas e em quais situações/cenários

Comparei o que a ER Clinic apresentou com o material da disciplina (repositório da turma e o meu, com anotações, códigos e exercícios). Quase toda técnica da palestra tem um correspondente visto em aula:

Técnica / cenário na ER Clinic	O que já vimos nas aulas
XGBoost para risco de falta (classificação)	Predição supervisionada: rotular com treino por amostras (quadro branco, semana 4) e XGBoost entre os modelos comuns de predição; os exercícios de internação e compra.
ROC AUC, Average Precision, Brier Score	Matriz de confusão, acurácia e F1-Score (guia de métricas). A ER Clinic usa métricas mais finas, que medem ranqueamento e calibração da probabilidade.
Atualizar e reavaliar o modelo	Última etapa do fluxo de predição: deploy e monitoramento, com *data drift* e retreino.
Chatbot, resumo e transcrição (LLM)	Pipeline de LLM (tokenização, embeddings, Transformer, geração) e uso de API (Gemini e OpenAI), com cobrança por tokens de entrada e saída.
Prompt Engineering	Estrutura de prompt em partes (contexto, tom, regras, exemplos, formato de saída).
JSON estruturado nos exames e resumos	Atividade da semana 10: enviar e receber dados em JSON predefinido.
Córtex (RAG, embeddings, base vetorial)	Fluxo de RAG (documentos, embeddings, base vetorial, busca por similaridade, LLM) e *top_k* com limiar de similaridade na avaliação.
Exames e voz (leitura de imagem e áudio)	Reconhecimento de padrões (imagem, voz, texto) e recomendação e apoio à decisão no mapa mental.

5.2 Relação situação/cenário × técnica à luz das aulas

A palestra confirma na prática a regra vista em aula de escolher a técnica pelo problema: classificar com base histórica é predição (XGBoost); gerar ou resumir texto é LLM; responder com base em documentos próprios é RAG. O guia de métricas ajuda a criticar o modelo de faltas: como faltar costuma ser a classe minoritária, a acurácia sozinha enganaria, e é coerente a ER Clinic usar métricas além dela. Também vale a nossa regra do *data leakage*: só entram variáveis conhecidas no momento do agendamento, como faltas anteriores, horário e convênio. O que a palestra trouxe de novo foram o reconhecimento de fala, o modelo multimodal, o fluxo de agentes no N8N e o processamento assíncrono (Celery), temas que as aulas ainda não cobriram.

6. Conclusão

A ER Clinic mostrou que não existe uma IA única para a clínica: cada etapa da jornada do paciente recebeu a técnica que cabe no seu tipo de dado e de tarefa, sempre com o profissional como responsável final. A lição para quem desenvolve é que a escolha da técnica, os cuidados com o dado e a supervisão humana são partes do mesmo projeto.